


三、研究計畫內容（以中文或英文撰寫）：

（一）研究計畫之背景。

當前的人工智慧技術（特別是所謂的「深度學習」）在許多應用上（如：影像辨識、語音辨識、自然語言處理等）有極其亮眼之表現，往往能提供高辨識率之精準預測結果。這樣具備高辨識率之預測模型有非常廣泛之應用價值，但在某些應用情境下（如：醫療診斷、金融決策、詐欺評估、法律判決、安全決策、無人駕駛車、軍事決策輔助系統等），它卻有個致命的缺點：缺乏解釋性。雖然有些人認為只要預測模型具備高準確率就可以安心直接使用，沒必要還需要去解釋原因。但有些領域的決策是需要有適當的解釋和因果關係的推論支撐，才能讓人們可以對相關的決策覺得具合理性和感到安心。模型若缺乏解釋性就會導致部分使用者的信心不足，而具備可解釋性的模型則能大大提高使用者的信心度。此外，可解釋的人工智慧也可以幫助開發人員改進人工智慧演算法的缺點，可以透過檢測數據中的偏差問題，發現模型中的錯誤，並修補演算法的弱點。

在此，我們就以先進車輛輔助系統和無人駕駛車為例子，來說明高準確率有可能導致行車危險的事件發生。越來越多的國家都制定車輛需要加裝先進車輛輔助系統（Advanced Driver Assistance Systems, ADAS）來為駕駛人提供車輛的工作狀況與車外的行駛環境變化等資訊以提高行車安全。雖然深度學習的模型在有足夠多的交通號誌代表樣本的訓練之下，能得到令人十分滿意的高辨識率，但有一些極端的例子，透過某種數位攻擊（digital attack）的方式讓原本正常的交通號誌加入特定的雜訊後，雖然對人類肉眼來看仍是正常的交通號誌，但就會讓深度學習的預測模型做出錯誤的判斷，如圖一所示。原本應該是「停止」的標誌卻會被錯誤地分類為「最大速限 100」！這樣子的錯誤判斷會導致先進車輛輔助系統和無人駕駛車產生極大之危險且有時是具致命性的錯誤判斷。而我們知道交通號誌經常會有汙損會某種程度的破壞（如：髒污、毀損等），如圖二所示，我們無法保證這種汙損不會造成類似之錯誤判斷。上述之範例要說明的是，高準確率之深度學習的預測模型有時會做出令人訝異的錯誤判斷，而這些判斷對人類的肉眼來說是極為不可思議的低級錯誤判斷。



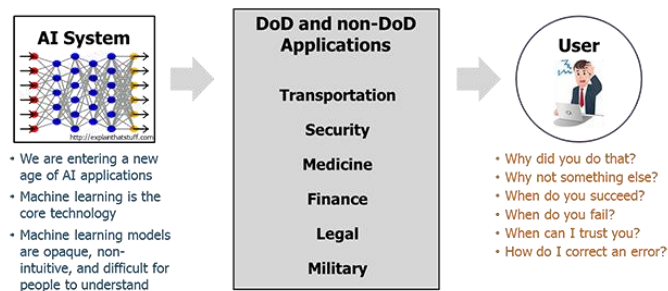
圖一、遭數位攻擊後之交通號誌錯誤辨識範例（摘自 <https://deep.ghost.io/robust-attribution/>）。



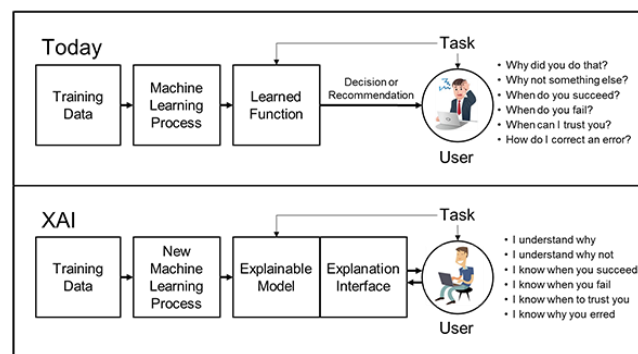
圖二、汙損會某種程度的破壞之交通號誌範例 (摘自 Google 圖片)。

另外，在醫療場域的應用也會遇到類似的情形。若遇到生死關頭的醫療建議，如：頭顱手術或重大器官摘除手術等，病人有時很難完全聽從一個黑盒子（深度學習的預測模型）的醫療建議，即使這個黑盒子有極高之準確率。所以，醫生須要告訴病人為何深度學習的預測模型會做出如此之判斷和醫療建議，否則，醫生很難說服病人要展開極度危險之侵入式或剛進行人體試驗之藥物治療。

美國國防部的 DARPA 單位在 2016 年就提出 20 億美元的新一代 AI 計畫，其中特別強調 Explainable Artificial Intelligence (XAI) 的重要性，DARPA 的資料 [1]，我們可以用圖三和圖四來說明可解釋性可以用在那些應用領域和必要性何在。



圖三、可解釋的 AI (XAI) 的應用領域 [1]。



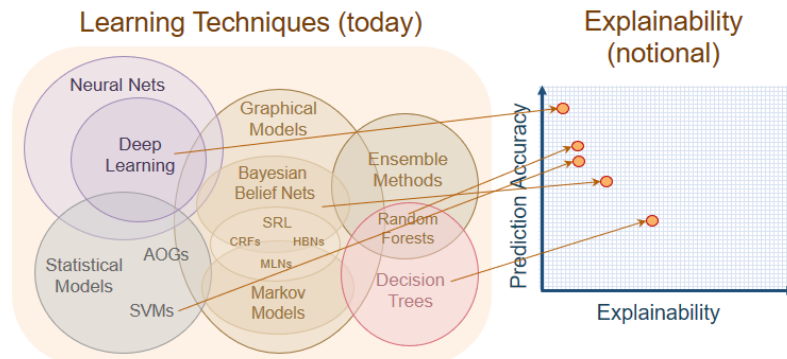
圖四、可解釋的 AI 的整體概念 [1]。

圖三和圖四顯示了 XAI 的需求和發展方向，指出 XAI 可以替人們回答那些問題：(1) 為何 AI 決定這麼做？(2) 為何不那麼做？(3) 為何可以成功？(4) 為

何會失敗？(5) 為何人們可以信任 AI？(6) 人們該如何修正錯誤？這些問題，也正點出了可解釋的 AI 科技需要解決的挑戰。這個 Explainable AI (XAI) 計劃旨在創建一套機器學習技術，這些技術可以：(1) 產生更多可解釋的模型，同時保持高水平的學習表現（預測準確性）和 (2) 使人類用戶能夠理解、適當信任並有效管理新興的人工智慧合作夥伴。

既然 XAI 是如此地重要，我們該如何達成這個研究目標呢？我們首先回顧整個人工智慧的發展歷史，可以發現人工智慧原先有兩大不同的發展方向：(1) 符號人工智慧 (Symbolic AI) 和 (2) 類神經網路。早年符號人工智慧 (Symbolic AI) 的發展主軸之一就是專家系統，專家系統本身就是透過大量規則來模擬專家的知識和判斷，所以，專家系統的可解釋性很高。至於類神經網路則是透過層層複雜的矩陣運算後才得到輸出結果，這樣的運算方式雖然可以從訓練資料迴歸出高準確率的輸入/輸出的關係，但對人類來說是缺乏可解釋性的，特別是近幾年的深度學習模型快速崛起之後，層數越來越深，導致不可解釋的問題變得越來越嚴重。

整體上，我們可以用圖五來說明現有模型的預測準確度和可解釋性成反比的關聯性。



圖五、現有模型的預測準確度和可解釋性成反比的關聯性 [2]。


通常模型結構越簡單（如：線性迴歸）越具備可解釋性，但也由於結構簡單則導致難以處理比較複雜的問題；

$$y_j = \sum_{i=0}^p w_{ji} x_i \left(= \underline{w}_j^T \underline{x} \right) = w_{j0} + w_{j1} x_1 + \dots + w_{jp} x_p \quad (1)$$

反之，越複雜的模型（特別是現在廣被採用的深度學習模型）則可以得到較高的準確度，但深度學習模型結構複雜則導致人類難以理解其特徵與結果的關係。所以，有時在高準確率和高解釋性必須做一定程度上的取捨。

近幾年來，陸續有許多研究者投入 XAI 的研究 [3]-[14]，大致上，可以分為兩種不同的解決方案：(1) 發展同時具備高解釋性與準確性的全新模型框架，模型本身就具備可解釋性來提升模型的透明度 (transparency) 和 (2) 發展模型的事後可解釋方法，以「事後歸因」 (post-hoc explanations) 的方式來解讀模型。

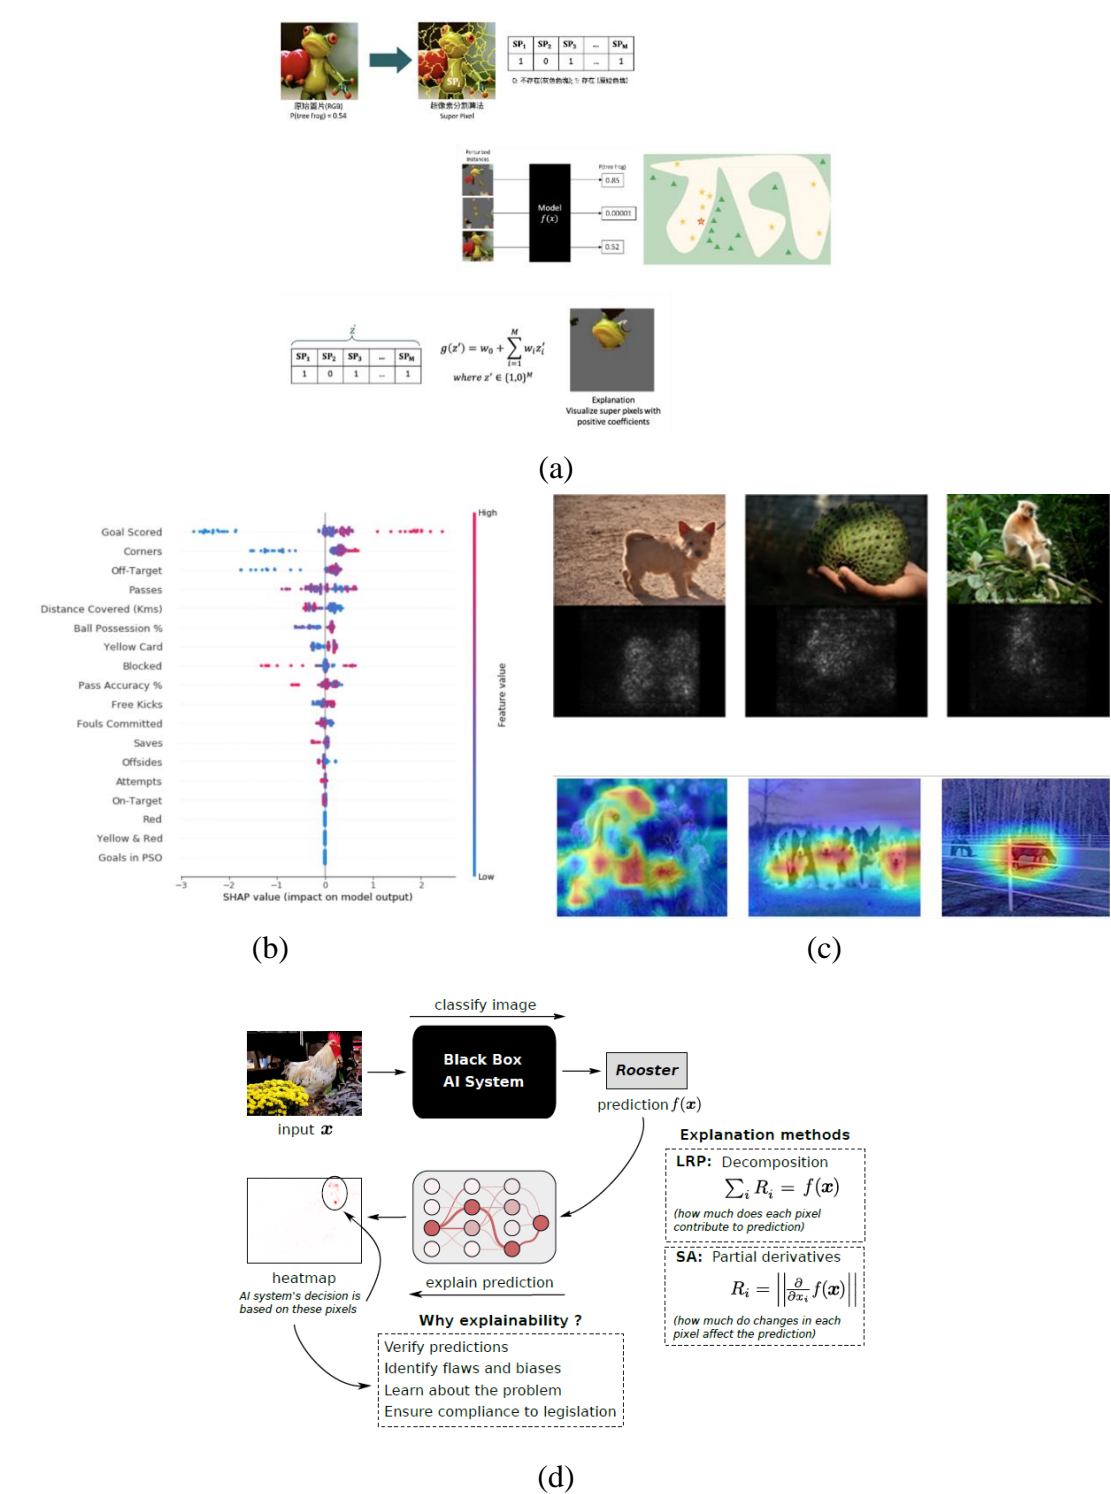
第一種解決方案最具代表性的方案就是決定樹 (decision tree) (如圖六 (a) 所示)，其實在 1990 年代就已有一些可行的做法，如：the nested generalized example (NGE) algorithm [15], the fuzzy adaptive learning control network (FALCON) [16], the fuzzy min-max neural network classifier (FMMC) (如圖六 (b) 所示) [17], adaptive-network-based fuzzy inference systems (ANFIS) [18], HyperRectangular Composite Neural Networks (HRCNNs) (如圖六 (c) 所示) [19]。但上述的解決方案須搭配有效之特徵擷取方法才能提供高準確度之輸出結果，適合處理維度不是非常高，並且較屬於非純影像型特徵的應用範疇 (如：醫療決策、金融決策、法律判決交通事故裁決等)。



圖六、第一種解決方案的模型：(a) 決定樹 (decision tree)、(b) FALCON [16]、(c) HRCNNs [19]。


對於現今講求所謂的 end-to-end 的深度學習的解決方式，特別是影像辨識、語音辨識或自然語言處理等應用領域來說，整體模型的架構更深層且更複雜，目前還未有一個有效的解決方案，可以同時發展出具備高解釋性與準確性的全新模型框架。所以，現今針對深度學習模型的可解釋性大都是採用第二種的「事後歸因」的方式，此類解決方式則有 LIME (如圖七 (a) 所示) [20]、SHAP (如圖七 (b) 所示) [21]、saliency map (如圖七 (c) 所示) [22]、sensitivity analysis (SA) (如圖七 (d) 所示) [23]、layer-wise relevance propagation (LRP) [24] (如圖七 (d) 所示) 等方法。LIME 的做法是在訓練出 DNN 模型後，再針對一筆訓練資料 (如：一張圖) 中的局部資料進行干擾，以便觀察該局部資料是否會影響預測結果，而來判斷訓練資料中的那個部分對預測結果具有更關鍵的作用；SHAP 將模型的預測值解釋為每個輸入特徵的歸因值之合，換句話說，就是計算每一個特徵的 shapley value，依此來衡量特徵對最終預測值的影響；而繪製顯著圖 (saliency map) 則是另一種廣為被使用的方法，它可以讓我們了解一張圖片中有哪些特定部位對模

型結果預測的影響較大。SA 的解釋姓是基於模型的局部評估梯度的預測，它假設最相關的輸入特徵會對輸出最敏感。與 SA 的方法不同，LRP 是根據最大狀態的預測不確定性來提供解釋，它使用局部重新分配的方式，向後重新分配預測規則，直到它為每個輸入變量分配一個相關性分數。



圖七、第二種解決方案的模型：(a) LIME [20]、(b) SHAP [21]、(c) saliency map [22]、(d) SA and LRP [23]。

正如上述文獻的分析和探討，可解釋性的 AI(XAI) 在某些特定的應用領域有其發展的必要性。所以，在這個三年期的計畫中，我們預計要大膽地提出一種新的深度學習的模型，要挑戰只能透過「事後歸因」的解決方式。希望第一年所開發出來的全新模型框架可以在發展的過程中，就同時具備解釋性與準確性，讓模型本身就具備可解釋性來提升模型的透明度。這想法是基於 J.Hawkins 和 S. Blakeslee 在 On Intelligence 這本書的假說 [25]，大腦皮質的任何區域都是在找出輸入間的關係，去記住它們之間的序列關係，再用這個記憶去預測這些輸入未來該如何表現，不變的特徵是發生在各個皮質階層中，階層性的特徵是存在於外界和大腦之中，在整個皮質中，所有的感覺皮質及聯接區都是一體，所有的預測都是來自經驗的學習，這些學習和特徵的表現都發生在所有掌管感覺的皮質區域，如圖八所示。



圖八、不變的特徵是發生在各個皮質階層中 [25]。

J.Hawkins 和 S.Blakeslee 在此書中首度提出階層式時序記憶 (Hierarchical temporal memory, HTM) 的概念，它又稱作分層時序記憶或層級實時記憶，是一種受生物學制約的智力理論 (或模型)。HTM理論是根據「神經科學」以及哺乳動物 (尤其是人類) 大腦新皮層中的「錐體神經元生理反應」、「錐體神經元間的相互作用」來開發。HTM的精髓在於其學習演算法可以進行儲存、學習、推論和長序列回憶。與大多數其他機器學習方法不同，HTM會連續地 (以無監督方式) 在未標記資料中學習基於時間的模式 (patterns)。它們認為大腦儲存的是「序列的序列」，因為真實世界的物體都是由一致出現的次部件所組成，皮質的每個區域都有它各自熟悉的序列目錄。這些序列都有「序名」，就是由一組細胞集體發射來代表，活化的「序名」會依序往上傳遞，越往上走，穩定性越高，階層性的構築序列允許我們分享和重複使用低階的物件，如：音素、字、詞、句子、文章等，又或者是線條、眼睛、鼻子、嘴巴、臉、動物等。我們預計採用多層自我組織映射圖 [26] 為基礎，結合卷積類神經網路 (Convolutional Neural Network, CNN) 的部分精神來實現HTM 的概念，以提出同時具備解釋性與準確性的深度學習模型。

在第二年的計劃中，會採用第一年所開發的新模型應用於心臟血管鈣化偵測

系統的開發。對醫生來說，要從大量的心臟血管的CT醫學影像中標註出鈣化斑塊是一項頗耗費時間與精力的工作。因此，第二年的計劃希望能夠將醫學影像處理技術和新模型做結合，來開發出一套心臟血管鈣化偵測系統，以便減輕醫師的工作量以及減少因疲勞而升高的誤判率，此外，最重要的是此系統可以供解釋性，方便醫生做最後之評估和日後模型之改善。

在第三年的計劃中，預計會採用第一年所開發的新模型應用於應用於大腸息肉偵測及分類系統的研究。大腸癌為我國十大癌症死亡率第三名及發生率之首[27]。根據研究顯示，約有九成的大腸癌是由大腸息肉所演變，因此如果病人的大腸管腔內生有腺瘤性息肉且沒有即時進行切除的話，在未來就有極高度的風險產生癌變。因此，如何辨識出息肉的分類及未來癌變的風險極為重要。然而，對於內視鏡醫生來說，要在彎曲且充滿皺折的腸道內先找到所有息肉的位置，並且切換到窄頻影像內視鏡 (Narrow band image, 簡稱 NBI) 或是噴灑染劑，以即時做出是否應立即切除的診斷是一項頗耗費精力的工作，很容易遺漏息肉。因此今年的計畫是希望能夠將醫學影像處理技術與深度學習做結合，來開發出一套大腸息肉偵測及分類系統，輔助醫生能夠更快速且精準的定位息肉在大腸中的位置，並且在不進行窄頻影像切換的情況下能夠更準確的診斷息肉的類型。

參考文獻

- [1] M. Turek, “Explainable Artificial Intelligence (XAI).” <https://www.darpa.mil/program/explainable-artificial-intelligence>.
- [2] M. Turek, DARPA- Explainable Arti_cial Intelligence (XAI) Program (2017), https://www.darpa.mil/program/explainable-arti_cial-intelligence.
- [3] J. Chen, X. Wu, V. Rastogi, Y. Liang, and S. Jha. "Robust Attribution Regularization," arXiv preprint arXiv:1905.09957 (2019). <https://arxiv.org/abs/1905.09957>.
- [4] C. Molnar, Interpretable Machine Learning: A Guide for Making Black Box Models Explainable, lulu.com, 2021.
- [5] Z. C. Lipton, “The mythos of model interpretability,” *arXiv preprint arXiv:1606.03490*, 2016.
- [6] T. Miller, “Explanation in artificial intelligence: Insights from the social sciences,” *Artificial Intelligence*, 2018.
- [7] A. Ghorbani, A. Abid, and J. Y. Zou. Interpretation of neural networks is fragile. CoRR, abs/1710.10547, 2017.
- [8] A. S. Ross and F. Doshi-Velez. “Improving the adversarial robustness and interpretability of deep neural networks by regularizing their input gradients,” in Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence, (AAAI-18), pages 1660–1669, 2018.


- [9] K. Simonyan, A. Vedaldi, and A. Zisserman, “Deep inside convolutional networks: visualising image classification models and saliency maps,” arXiv preprint arXiv:1312.6034, 2013.
- [10] F. K. Došilović, M. Brčić, and N. Hlupić, “Explainable artificial intelligence: a survey,” 2018 41st International Convention on Information and Communication Technology, Electronics and Microelectronics (MIPRO), 2018.
- [11] S. R. Islam, W. Eberle, S. K. Ghafoor, and, M. Ahmed, “Explainable Artificial Intelligence Approaches: A Survey,” arXiv:2101.09429, 2021.
- [12] E. Tjoa, and C. Guan, “A Survey on Explainable Artificial Intelligence (XAI): towards Medical XAI,” IEEE Transactions on Neural Networks and Learning Systems, Vol. 32, No.11, pp. 4793-4813, 2021.
- [13] F. Xu, H. Uszkoreit, Y. Du, W. Fan, D. Zhao, and J. Zhu,” Explainable AI: A Brief Survey on History, Research Areas, Approaches and Challenges,” Natural Language Processing and Chinese Computing, 2019.
- [14] M. Danilevsky, K. Qian, R. Aharonov, Y. Katsis, B. Kawas, and P. Sen, “A Survey of the State of Explainable AI for Natural Language Processing,” Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing, pp. 447–459, 2020.
- [15] S. L. Salzberg, Learning with nested generalized exemplars. Academic: Kluwer; 1990.
- [16] C-T Lin and C. S. G. Lee, “Neural-network-based fuzzy logic control and decision system,” IEEE Trans on Computers, Vol. 40, No. 12, pp. 1320–36, 1991.
- [17] P. K. Simpson, “Fuzzy min-max neural networks-Part 1: Classification,” IEEE Trans. on Neural Networks, Vol. 3, pp. 776–86, 1992.
- [18] J.- S. R. Jang, “ANFIS: adaptive-network-based fuzzy inference systems,” IEEE Trans. on Systems, Man and Cybernetics, Vol. 23, No. 3, pp. 665–85, 1993.
- [19] M. C. Su, “Use of neural networks as medical diagnosis expert systems,” Computers in Biology and Medicine, Vol. 24, No. 6, pp. 419–29, 1994.
- [20] M. T. Ribeiro, S. Singh, and C. Guestrin, “Why Should I Trust You?”: Explaining the Predictions of Any Classifier,” Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pp. 1135–1144, 2016.
- [21] S. M. Lundberg and S.-I. Lee, “A Unified Approach to Interpreting Model

- Predictions,” Advances in Neural Information Processing Systems 30 (NIPS 2017), pp. 4765--4774, 2017.
- [22] K. Simonyan, A. Vedaldi, and A. Zisserman, “Deep Inside Convolutional Networks: Visualising Image Classification Models and Saliency Maps,” arXiv:1312.6034, 2013.
- [23] Samek, W., Wiegand, T., Müller, K.R.: Explainable artificial intelligence: Understanding, visualizing and interpreting deep learning models. arXiv preprint arXiv:1708.08296 (2017).
- [24]. Simonyan, K., Vedaldi, A., Zisserman, A.: Deep inside convolutional networks: Visualising image classification models and saliency maps. In: 2nd International Conference on Learning Representations, ICLR 2014, Banff, AB, Canada, April 14-16, 2014, Workshop Track Proceedings (2014), <http://arxiv.org/abs/1312.6034>.
- [25] J. Hawkins and S. Blakeslee, On Intelligence: How a New Understanding of the Brain Will Lead to the Creation of Truly Intelligent Machines, Times Books, 2004. 洪蘭 譯，《創智慧》，2006，遠流。
- [26] T. Kohonen, *Self-Organization and Associative Memory*, 3rd ed. New York, Berlin: Springer-Verlag, 1989.
- [27] 衛生福利部國民健康署，108 年癌症登記報告。


(二) 研究方法、進行步驟及執行進度。

第一年：研發基於多層自我組織映射圖之可解讀性之深度學習模型

本計畫的第一年採用多層自我組織映射圖 (Self-organizing Feature Map，簡稱 SOM) 為基礎，結合卷積類神經網路 (Convolutional Neural Network, CNN) 的部分精神來實現 HTM 的概念，以提出同時具備解釋性與準確性的深度學習模型 (如圖九所示)。整體構想是基於人類的視覺神經系統的運作機制，當外界的物件透過視網膜的成像後，會將視覺刺激不斷地傳到下一層皮質區來處理，最後傳達大腦時，由大腦再做綜合判斷，才下指令來因應外界的刺激。




(a)



(b)

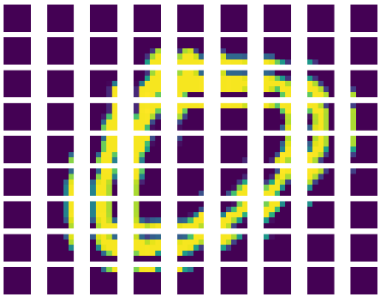
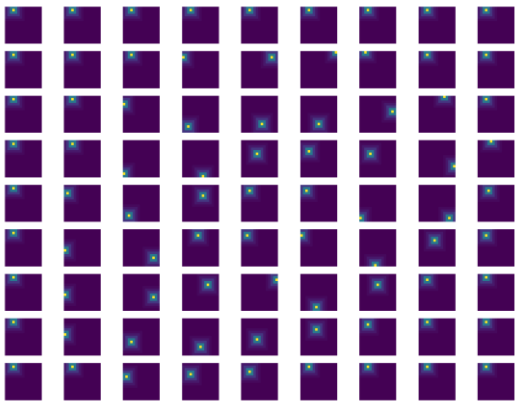
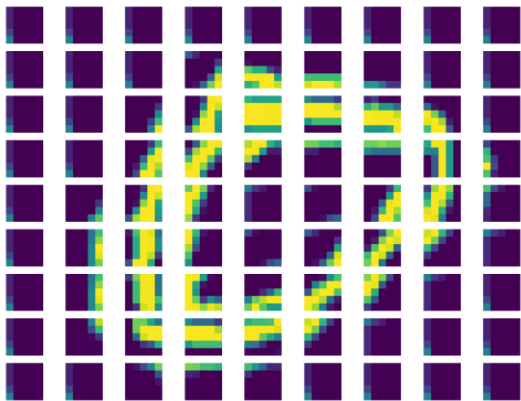

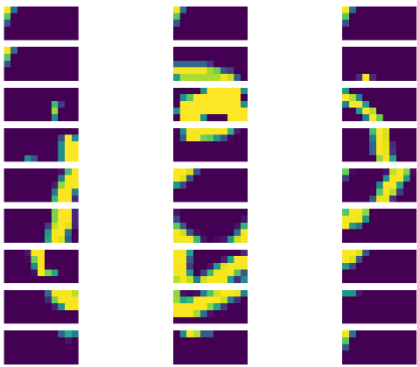
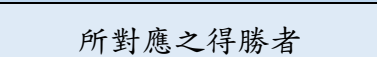
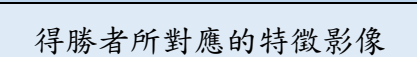
圖九、多層自我組織映射之可解讀性之深度學習模型架構圖：(a) 非監督度式學習模型、(b) 監督度式學習模型。

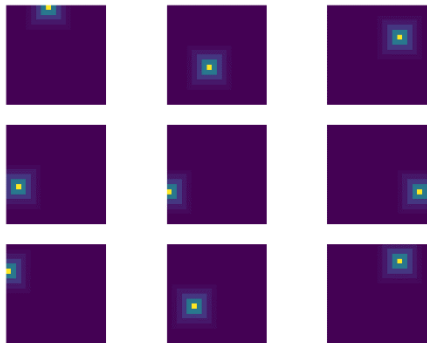
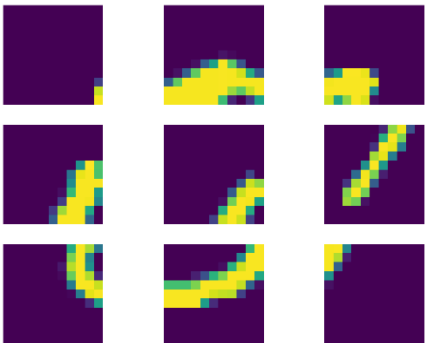


本架構將採用多層自我組織特徵映射圖為基礎，會將輸入影像切隔成大小相同的小影像（如圖十所示），每一層的特徵映射圖（Feature Map，簡稱 FM）會將切割影像或前一層的所形成之響應圖（Response Map，簡稱 RM）當作是輸入，然後，透過 SOM 演算法來形成 FM。所以，在此 FM 上的類神經元的鍵結值是這個切割影像或 RM 大小的影像。接著，這一層的 FM 會因為切割影像的陸續輸入而形成那一層的 RM，之後，再將此 RM 輸入下一層 FM，一直到所有切割影像都被掃描過。這個模型可以應用於非監督式學習（如圖九 (a) 所示）或監督式學習（如圖九 (b) 所示）。若是應用於非監督式學習，我們會透過適應共振理論（Adaptive Resonance Theory Network，簡稱 ART）[1]，讓最後的概念或群聚可以根據相似度的大小，自我決定邀分成幾種概念或群聚，這樣的做法不用事先設定想要形成的概念或群聚數目。若是應用於監督式學習，我們會接一層線性單元來做分類或迴歸，採用一層線性單元的原因是為了可解釋性，因為多層的感知機會增加解釋上的困難。最後，我們透過可視覺化，將每層的 RM 轉換成具有解讀性特徵影像，使人可以有效的解讀特徵所賦予的意義（如圖十一所示）。



圖十、切割手寫數字—0。

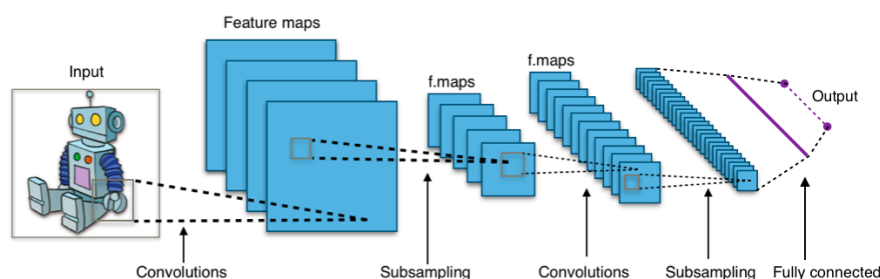
輸入影像之切割圖

	
第一層	
切割圖所對應之得勝者	得勝者所對應的特徵影像
	
第二層	
所對應之得勝者	得勝者所對應的特徵影像
	
第三層	
所對應之得勝者	得勝者所對應的特徵影像
	

	
第四層	
所對應之得勝者	得勝者所對應的特徵影像
	

圖十一、每層之得勝者以及特徵對應圖（手寫數字：0）。

與卷積類神經網路相同的地方都是多層的架構（如圖十二所示），但不同的地方是，卷積類神經網路採用卷積層（Convolutional layer）將前一層的特徵圖（Feature Map）以有限受激範圍的方式處理成新的特徵圖，之後，再搭配池化層（Pooling layer）將新的特徵圖予以縮小，如此重複多層，最後搭配全連結層（Fully connected layer），輸出層的神經元數目由使用者事先根據訓練資料選定的，然後透過梯度法來進行分類或迴歸的處理。基本上，特徵圖的大小會隨著層數的增加而逐漸變小。



圖十二、卷積類神經網路架構圖 [2]。

但我們想要開發的多層自我組織映射之之可解讀性之深度學習模型是要在

每一層中，要逐漸形成更高階的響應圖 (Response Map)，然後將此響應圖當作下一層 SOM 的輸入，如此一來，就會像是階層式時序記憶 (Hierarchical temporal memory, HTM) 一樣，最低階的 SOM 會形成基本組件，如：線條，由一些基本的線條再組成高一階的特徵，如：各種幾何圖形、眼睛、鼻子、嘴巴、臉、動物等

網路訓練：訓練架構又可細分為三部分。第一部份：對影像作切割；第二部份：將切割影像經過層層的處理；第三部份：將最後的結果，記錄下來，以便下次辨識。一開始會對輸入影像做切割，形成最小單位的影像大小稱為基礎影像。再將這些基礎影像送入網路架構中。

在這步驟相當於每一層的皮質層正在學習一些新物體，將其特徵記錄下來，並且產生出下一層能夠辨識的資訊。到最後一層的 RM 生成時，若是應用於非監督式學習，我們會透過適應共振理論模型來學習概念或群聚，讓最後的概念或群聚可以根據相似度的大小，自我決定邀分成幾種概念或群聚，這樣的做法不用事先設定想要形成的概念或群聚數目。若是應用於監督式學習，我們會接一層線性單元來做分類或迴歸，再採用最陡坡降法來修正鍵結值。

首先，數學符號的定義如下：

FM_i ：第 i 層的特徵映射圖 (Feature Map)。

RM_i ：第 i 層的特徵映射響應圖 (Response Map)。

I_H 、 I_W ：輸入影像的長和寬。

f_H 、 f_W ：切割成基礎影像的長和寬。

$FM_h(i)$ 、 $FM_w(i)$ ：第 i 層特徵映射圖的長和寬。

$WC_h(i)$ 、 $WC_w(i)$ ：在第 i 層所需要組合的方式每次取 $WC_h(i)$ 列，取 $WC_w(i)$ 行，疊加在一起成新的 RM_i 。

接下來，演算法步驟如下：

步驟一：決定整個網路架構的參數及層數。

步驟二：將輸入影像 ($I_H \times I_W$)，切割成大小為 ($f_H \times f_W$) 的基礎影像，總共有 $(\frac{I_H}{f_H} \times \frac{I_W}{f_W})$ 個影像，做為下一層的輸入資料 (如圖十三所示)。

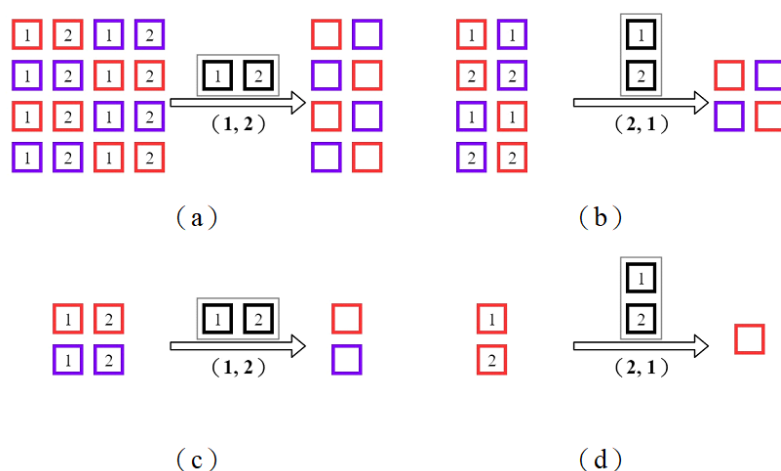
步驟三：根據 Su 與 Chang 所提出的加速 SOM 的方法 [3]，先透過 k-means 演算法，從所有的輸入影像之中，找到 $FM_h(i) \times FM_w(i)$ 個群聚中心。再將群聚中心當作 FM 的初始化，並對 FM 做 SOM 演算法的細調修正，生成出群聚中心的拓譜圖。

步驟四：利用 FM，找出每張輸入影像的得勝者，再經由 ($WC_h(i)$, $WC_w(i)$) 的

得勝次數 (Winner Count)，產生出有依發生順序之疊加後的 RM。如果 RM 的數量不等於原始輸入影像的數量，則將 RM 當作下一層的輸入資料，跳至 Step 3。如果 RM 的數量等於原始輸入影像的數量，則進入步驟五。

步驟五：若是應用於非監督式學習，我們會透過適應共振理論模型來學習概念或群聚，讓最後的概念或群聚可以根據相似度的大小，自我決定邀分成幾種概念或群聚，這樣的做法不用事先設定想要形成的概念或群聚數目。若是應用於監督式學習，我們會接一層線性單元來做分類或迴歸，再採用最陡坡降法來修正鍵結值。

步驟六：如果效果不好，則增加層數和不同的切割組合，回到步驟一，重新訓練。



圖十三、影像組合之示意圖 (a) 第一層 RM1 依照 (1, 2) 組合 (b) 第二層 RM2 依照 (2, 1) 組合 (c) 第三層 RM3 依照 (1, 2) 組合 (d) 第四層 RM4 依照 (2, 1) 組合。

預計可能之困難與解決途徑：

困難一：需要幾層的特徵映射圖？

解決途徑：目前需針對不同的問題試煉出不同大小的特徵映射圖。

困難二：每一層特徵映射圖的大小如何設定？

解決途徑：層數越大，所需要的尺寸也會隨著變大。

困難三：倘若學習向量量化網路對 ART 進行微調的效果不夠好時，如何解決？

解決途徑：考慮以下方案：(1) 再增加層數，以提高階層式特徵的有效性、(b) 此時必須仍得採用 LVQ 演算法 [4]或倒傳遞的訓練方式來推倒相關的梯度，以進行網路的訓練。可參考目前一些深度學習的開放框架，完成網路訓練。

困難四：倘若 Linear nodes 進行的分類或迴歸的效果不夠好時，如何解決？

解決途徑：考慮以下方案：(1) 再增加層數，以提高階層式特徵的有效性、(b) 此

時必須仍得採用倒傳遞的訓練方式來推倒相關的梯度，以進行網路的訓練。可參考目前一些深度學習的開放框架，完成網路訓練。

參考文獻：

- [1] G. A. Carpenter and S. Grossberg, "A massively parallel architecture for a self-organizing neural pattern recognition machine," Computer Vision, Graphics, and Image Processing, vol. 37, pp. 54-115, 1987.
- [2] "Convolutional neural network," Wikipedia, [Online]. Available: https://en.wikipedia.org/wiki/Convolutional_neural_network. [Accessed 17 - Jun - 2018].
- [3] M. C. Su and H. T. Chang, "Fast Self-Organizing Feature Map Algorithm," IEEE Transactions on Neural Networks, vol. 11, no. 3, pp. 721-733, 2000.
- [4] T. Kohonen, "Improved versions of learning vector quantization," IJCNN, vol. 1, pp. 545-550, 1990.

第二年：持續深化多層自我組織映射圖之可解讀性之學習模型，並應用於心臟血管鈣化偵測系統的開發

近年來，心血管疾病一直都是台灣前三大死亡原因，在全球更是最主要的死亡原因。如果病人的心臟鈣化指數高的話，就有極高度的心血管疾病的風險。對醫生來說，要從大量的心臟血管的 CT 醫學影像中標註出鈣化斑塊是一項頗耗費時間與精力的工作。因此，今年的計畫是希望能夠將醫學影像處理技術和深度學習做結合，來開發出一套心臟血管鈣化偵測系統，輔助醫生診斷心臟血管內的鈣化斑塊，減輕醫生的工作量，加快診斷速度，降低診斷錯誤的機率。此外，就是提供可解釋性，方便醫生從輸出結果來評估其合理性和後續的調整。

心血管疾病的問題不容忽視，在許多研究顯示冠狀動脈中的鈣化程度與心血管疾病有高度相關，在 2012 年 Yeboah 等人提出冠狀動脈的鈣化程度是心血管疾病中強而有力的預測因子 [1]，而原本做心臟相關檢查時，同時需要冠狀動脈的血管造影（CCTA）以及鈣化評分掃描（CSCT）兩種 CT 醫學影像，Pavitt 等人在 2014 年提出有 85% 的病人在鈣化評分掃描時分數高的同時在血管造影中也能看出鈣化程度很高 [2]，Mylonas 等人的實驗結果也顯示出兩種 CT 影像之間的高關聯性 [3]，而 Voros 等人則是提出在冠狀動脈血管造影中直接做鈣化評分，可以不需要拿到鈣化評分掃描影像，也可以減少 40~50% 的放射劑量 [4]，因此本計畫預計使用包含冠狀動脈的血管造影影像（CCTA）的心臟血管 CT 醫學影像。

在 1972 年，Dombal 等人做了急性腹痛的患者使用電腦輔助診斷（Computer-Aided Diagnosis, 簡稱 CAD）結果與臨床診斷結果的比較實驗 [5]，發現 CAD 的診斷結果準確率高達 91.8%，臨床診斷的準確率只有 79.6%，因此證明 CAD 在臨床實驗的環境中是可行的，Doi 在 2007 年提到 CAD 已經成為醫學影像和放射性診斷學的主要研究課題之一 [6]，用於偵測、分割或是分類，並非要取代醫師，


而是要協助醫師做診斷，CAD 已經運用的許多病症上，像是 Katsuragawa 等人開發了使用胸部 X 光來檢測肺結節與間質性肺病的變化的 CAD 系統 [7]；Schmid-Saugeona 等人開發了用於色素性皮膚病變的 CAD 系統 [8]，提供檢測病變的邊界以及量化其對稱程度的解決方法；Rangayyan 則開發了可以檢測出有乳腺癌跡象的 CAD 系統 [9]。

在 2016 年時，Wolterink 等人提出一種方法做量化冠狀動脈鈣化程度 (Cardiac Calcium Scoring CT, CSCT) [10]，使用監督式學習可直接辨識冠狀動脈鈣化以及量化鈣化斑塊程度（鈣化程度分數越高表示心血管疾病發生的機率越高），且不需要經過血管影像萃取的方式就可以達到效果。

2017 年，İşgum 等人使用 3D 的 CT 影像做為資料集，提出一個自動鈣化偵測的方法 [11]，其方法如下，首先設定一個閾值，將體積大於 1387 平方公厘的物件，都判定為不是鈣化斑塊，接著使用大小、形狀、位置等特徵提取出候選物件，最後使用 k-NN (K-Nearest Neighbor) [12] 已及 SVM (Support Vector Machine) [13] 做分類，而分類方式為正類樣本為鈣化斑塊，而負類樣本有包含非鈣化斑塊與其他在電腦斷層掃描中會掃出的高密度的東西，如：骨頭和雜訊。2018 年，我們實驗室的碩士生提出一種使用 CNN 偵測鈣化斑塊的方法 [14]，先擷取出血管影像，再將此影像切成大小為 15x15 做為訓練影像，分為包含鈣化斑塊（正類）與不包含鈣化斑塊（負類）兩類，然後，訓練一個有 5 層的卷積層和兩層全連接層的 CNN。

上述方法皆有其特定之優缺點，最重要的是這些方法皆無可解釋性，就只能完全依賴黑盒子般的輸出。我們這一年的計畫是要除了高準確率之外，還要提供可解釋性。

冠狀動脈中的鈣化斑塊，共分為三種，分別為鈣化斑塊 (calcified plaque，又稱硬斑塊)、非鈣化斑塊 (non-calcified plaque，又稱軟斑塊) 和混和斑塊 (mixed plaque，或稱 partially calcified plaque) [15]，鈣化斑塊的主要特徵在影像中，會看出有明顯的亮點，如圖十四 (a) 所示；非鈣化斑塊並不明顯，從影像中判斷時容易被忽略，因為非鈣化斑塊的部分，會比血管的部分更暗，很常會判斷成非血管的部分，如圖十四 (b) 所示；而混和斑塊則是如圖十四 (c) 所示，會同時有鈣化斑塊與非鈣化斑塊。本計畫預計是針對鈣化斑塊與混和斑塊進行偵測。




圖十四、鈣化斑塊種類：(a) 鈣化斑塊、(b) 非鈣化斑塊、(c) 混和斑塊。


所要開發的心臟血管鈣化偵測系統預計會需要包含以下四個模組：(1) 心臟血管擷取模組：利用影像處理技術，從心臟血管的 CT 醫學影像中擷取出冠狀動脈血管的部分 (如圖十五所示)、(2) 鈣化斑塊偵測模組：有兩種方法，第一種方法可考慮直接使用 YOLO v3 模型來偵測並且標記出鈣化斑塊的發生位置 [16]，但這種方法缺乏可解釋性；第二種方式就是將所擷取出血管影像切成大小為 15x15 的小影像，然後，採用第一年所開發的多層自我組織映射圖之可解讀性之學習模型與以辨識是否是鈣化斑塊的影像，這種方法是可以提供解釋性 (如圖十六所示)、(3) 鈣化斑塊血管分段定位模組：使用 CNN 模型或第一年所開發的多層自我組織映射圖之可解讀性之學習模型判斷鈣化斑塊的位置是在哪一條主動脈 (如：左冠狀動脈 (LCA)、右冠狀動脈 (RCA)、左前降支 (LAD)) 血管的上中下的哪個位置 (如圖十七所示)、(4) 編輯工具模組：可以搭配上上述的三個模組，在讀取心臟血管的 CT 醫學影像後，自動生成一張心臟鈣化評估報告圖，透過此編輯工具，可讓醫師直接增修圖上的鈣化斑塊的位置與數量，藉此減輕醫師的工作量 (如圖十八所示)。



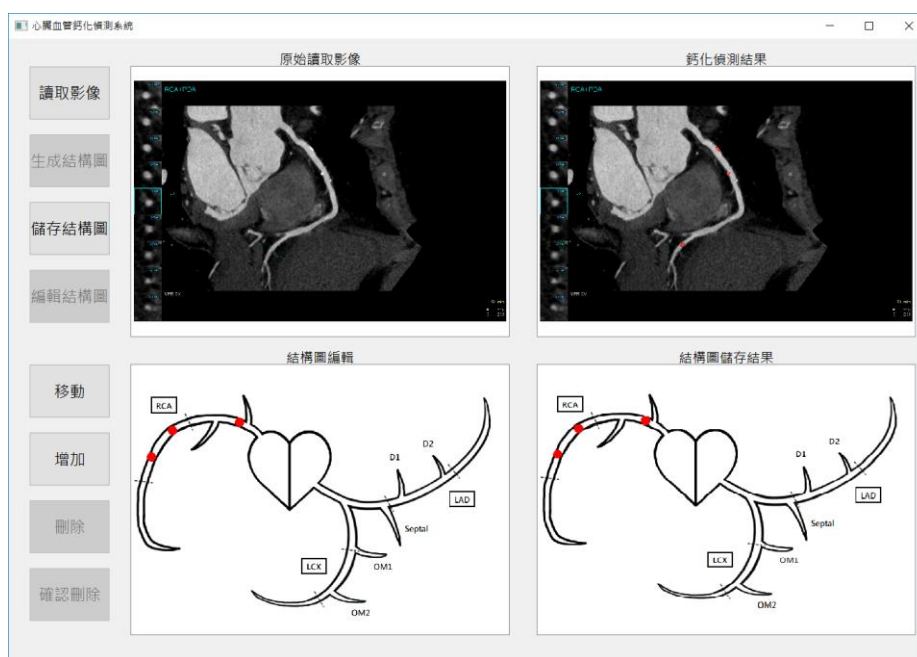
圖十五、心臟血管擷取模組：從 CT 影像中擷取出冠狀動脈血管的部分。



圖十六、鈣化斑塊偵測模組：標記出鈣化斑塊的發生位置。



圖十七、鈣化斑塊血管分段定位模組：鈣化斑塊的發生在哪個血管的上中下的位置。



圖十八、編輯工具模組：在讀取心臟血管的 CT 醫學影像後，自動生成一張心臟鈣化評估報告圖，並提供編輯功能讓醫生編輯增刪。

預計可能之困難與解決途徑：

困難一：鈣化斑塊偵測模組準確率萬一不夠高？

解決途徑：(1) 考慮採用更有效率之 YOLO 版本來應用或 (2) 再增加層數，以提高階層式特徵的有效性，來提升多層自我組織映射圖之可解讀性之學習模型的準確性。

困難二：鈣化斑塊血管分段定位模組準確率萬一不夠高？

解決途徑：(1) 考慮採用更廣或更深的 CNN 模型或 (2) 再增加層數，以提高階層式特徵的有效性，來提升多層自我組織映射圖之可解讀性之學習模型的準確性。

困難三：編輯工具模組能否滿足醫生實際應用需求？

解決途徑：因為鈣化斑塊偵測模組和鈣化斑塊血管分段定位模組準確率都不可能到百分之百正確，所以，自動化產製之心臟鈣化評估報告圖一定會有錯誤，此編輯工具必須能醫生自主調整鈣化斑塊的數目和位置。因此，編輯工具要能其他文書和繪畫之工具一樣，能讓自動化偵測的鈣化斑塊在報告書上手動增刪。

參考文獻：

- [1] J. Yeboah *et al.*, "Comparison of novel risk markers for improvement in cardiovascular risk assessment in intermediate-risk individuals," *Jama*, vol. 308,

no. 8, pp. 788-795, 2012.

- [2] C. W. Pavitt *et al.*, "Deriving coronary artery calcium scores from CT coronary angiography: a proposed algorithm for evaluating stable chest pain," *The international journal of cardiovascular imaging*, vol. 30, no. 6, pp. 1135-1143, 2014.
- [3] I. Mylonas *et al.*, "Quantifying coronary artery calcification from a contrast-enhanced cardiac computed tomography angiography study," *European Heart Journal–Cardiovascular Imaging*, vol. 15, no. 2, pp. 210-215, 2013.
- [4] S. Voros and Z. Qian, "Agatston score tried and true: by contrast, can we quantify calcium on CTA?," *Journal of cardiovascular computed tomography*, vol. 6, no. 1, pp. 45-47, 2012.
- [5] F. De Dombal *et al.*, "Computer-aided diagnosis of acute abdominal pain," *Br Med J*, vol. 2, no. 5804, pp. 9-13, 1972.
- [6] K. Doi, "Computer-aided diagnosis in medical imaging: historical review, current status and future potential," *Computerized medical imaging and graphics*, vol. 31, no. 4-5, pp. 198-211, 2007.
- [7] S. Katsuragawa and K. Doi, "Computer-aided diagnosis in chest radiography," *Computerized Medical Imaging and Graphics*, vol. 31, no. 4-5, pp. 212-223, 2007.
- [8] P. Schmid-Saugeona *et al.*, "Towards a computer-aided diagnosis system for pigmented skin lesions," *Computerized Medical Imaging and Graphics*, vol. 27, no. 1, pp. 65-78, 2003.
- [9] R. M. Rangayyan *et al.*, "A review of computer-aided diagnosis of breast cancer: Toward the detection of subtle signs," *Journal of the Franklin Institute*, vol. 344, no. 3-4, pp. 312-348, 2007.
- [10] J. M. Wolterink *et al.*, "Automatic coronary artery calcium scoring in cardiac CT angiography using paired convolutional neural networks," *Medical image analysis*, vol. 34, pp. 123-136, 2016.
- [11] I. Išgum *et al.*, "Detection of coronary calcifications from computed tomography scans for automated risk assessment of coronary artery disease," *Medical physics*, vol. 34, no. 4, pp. 1450-1461, 2007.
- [12] J. M. Keller *et al.*, "A fuzzy k-nearest neighbor algorithm," *IEEE transactions on systems, man, and cybernetics*, no. 4, pp. 580-585, 1985.
- [13] B. Scholkopf and A. J. Smola, *Learning with kernels: support vector machines, regularization, optimization, and beyond*. MIT press, 2001.
- [14] 唐嘉梅, "深度學習於醫學影像處理之應用," 碩士, 資訊工程學系, 國立中央大學, 桃園縣, 2018.
- [15] S. Voros *et al.*, "Coronary atherosclerosis imaging by coronary CT angiography: current status, correlation with intravascular interrogation and meta-analysis,"

JACC: Cardiovascular Imaging, vol. 4, no. 5, pp. 537-548, 2011.

[16] J. Redmon and A. Farhadi, "Yolov3: An incremental improvement," *arXiv preprint arXiv:1804.02767*, 2018.

第三年：持續深化多層自我組織映射圖之可解讀性之深度學習模型，應用於大腸息肉偵測及分類系統的研究

大腸癌為我國十大癌症死亡率第三名及發生率之首 [1]。根據研究顯示，約有九成的大腸癌是由大腸息肉所演變，因此如果病人的大腸管腔內生有腺瘤性息肉且沒有即時進行切除的話，在未來就有極高度的風險產生癌變。因此，如何辨識出息肉的分類及未來癌變的風險極為重要。Kudo 等人發展出染色內視鏡 (chromoendoscopy) 和內視鏡廠商如 Olympus 推出窄頻影像內視鏡 (Narrow band image, NBI)，就是利用息肉表面在染料下的 pit pattern [2]或是在特殊波長可見光下的微血管表徵 (microvascular pattern) [3]，分辨息肉可能為無風險之增生性息肉 (hyperplastic polyp)、良性但有癌變風險之腺性息肉 (adenoma)，以及早期黏膜下癌 (submucosa cancer) 或是侵襲癌 (advanced cancer)，NBI 國際大腸直腸內視鏡 (NBI International Colorectal Endoscopic, NICE) 分類分別為 NICE classification type 1、type 2 和 type 3。因此 Iwatate 等人發表以 NBI 判斷，若是 NICE type 3 則另外做染色內視鏡以決定是否可以內視鏡切險或是手術的方法 [4]。


然而，對於內視鏡醫生來說，要在彎曲且充滿皺折的腸道內先找到所有息肉的位置，並且切換到 NBI 或是噴灑染劑，以即時做出是否應立即切除的診斷是一項頗耗費精力的工作，很容易遺漏息肉。因此今年的計畫是希望能夠將醫學影像處理技術與深度學習做結合，來開發出一套大腸息肉偵測及分類系統，輔助醫生能夠更快速且精準的定位息肉在大腸中的位置，並且在不進行窄頻影像切換的情況下能夠更準確的診斷息肉的類型。

大腸癌的防治問題不容忽視，研究顯示約有九成的大腸癌是由大腸息肉所演變 [5]，在 1993 年，Sidney 等人提出定期進行結腸鏡檢查並切除息肉可以有效預防大腸癌的發生 [6]。在 2017 年，Kim 等人分析了 463 名患者和 1294 顆腫瘤性息肉後發現醫生在進行大腸鏡檢查的時候，平均會漏掉 24% 可能會癌變的腺瘤性息肉 [7]。在 2017 年，Komeda 等人使用 1800 張影像訓練了一個簡單的兩層的卷積神經模型用於進行息肉分類，並得出若進一步研究，在未來 CNN-CAD 系統可能有助於快速診斷結直腸息肉分類 [8]。在 2020 年，Krushi Patel 等人將六個知名的 CNN 模型應用於分類增生性息肉和腺瘤性息肉，並比較其效果，其中 VGG19 表現最為突出，可以有接近 79% 的準確率 [9]。

上述方法皆有其特定之優缺點，最重要的是他們都有使用 NBI 的影像來進行訓練，必須依賴醫生切換光源來對息肉進行診斷。因此我們這一年的計畫除了提高準確率之外，還要研發能夠凸顯白光底下息肉紋路的方法，輔助醫生在不進行光源切換的情況下更好的進行判斷。


大腸息肉共分為兩種如圖十九所示，分別為增生性息肉 (hyperplastic polyps，

又稱化生性息肉) 與腺瘤性息肉 (adenomatous polyps, 又稱息肉狀腺瘤), 其中增生性息肉在日後轉變為惡性腫瘤的機率非常低, 因此被認為是良性的不用切除, 但是腺瘤性息肉被認為有很高的機率持續長大最終演變成腺癌 (adenocarcinoma), 因此不論大小建議直接切除。



圖十九、大腸息肉種類：(a) 增生性息肉、(b) 腺瘤性息肉、(c) 腺癌。

傳統白光的光線強, 照明範圍廣, 能夠幫助醫生在狹窄的腸道內有更好的視野範圍找出息肉所在的位置, 然而傳統白光底下, 大腸息肉的顏色與腸道黏膜的顏色十分接近, 且用來判斷息肉種類的表面紋路與周圍的顏色幾乎融在一起 (如圖二十 (a) 所示)。因此, 目前醫生在確認息肉的位置後, 會將光源切換為窄頻影像 (Narrow Band Imaging, 簡稱 NBI), 凸顯息肉紋路的對比度 (如圖二十 (b) 所示), 以利後續更好的判斷病灶的範圍以及息肉的種類。本計畫預計利用機器學習和影像處理的方式來凸顯白光影像中息肉表面紋路的對比度, 並利用深度學習對處理過的白光息肉影像進行分類。



圖二十、(a) 傳統白光息肉影像、(b) NBI 息肉影像。

所要開發的大腸息肉位置偵及分類測系統預計會需要包含以下五個模組：(1) 大腸息肉偵測模組：有兩種方法, 第一種方法可考慮直接使用 YOLO v7 模型來偵測並且標記出鈣化斑塊的發生位置 [10], 但這種方法缺乏可解釋性; 第二種方式就是將所擷取出血管影像切成小影像, 然後, 採用第一年所開發的多層自我組織映射圖之可解讀性之學習模型與以辨識是否是鈣化斑塊的影像, 這種方法是可以提供解釋性, 如圖二十一所示、(2) 大腸息肉紋路強化模組：有兩種方法, 第一種方法考慮利用影像處理技術強化息肉紋路的特徵, 如圖二十二所示; 第二種


方法考慮利用機器學習，透過嘗試組合不同色彩空間的特徵找出白光到 NBI 的轉換公式，如圖二十三所示。如果採用方法二，本計畫同時需要解決白光影像與 NBI 影像的校正問題，因為實際進行大腸鏡檢查時，醫生需要手動切換光源，導致息肉在兩種不同光源底下的影像通常無法完全匹配，會有些許角度上的差異、(3) 白光與 NBI 影像分類模組：目前已知的公開資料集 (如：西班牙的 Piccolo datasets [11]等) 都同時包含白光影像與 NBI 影像，因此訓練 CNN 模型或第一年所開發的多層自我組織映射圖之可解讀性之學習模型來進行自動分類，再透過人工進行檢查排除少數錯誤分類的影像，藉此大幅提升大腸息肉分類訓練資料集準備的速度、(4) 大腸息肉分類模組：使用 CNN 模型或第一年所開發的多層自我組織映射圖之可解讀性之學習模型，搭配強化過息肉紋路的白光影像進行訓練、(5)大腸鏡整合模組：將上述三個模組與大腸鏡進行整合後，在醫生進行大腸鏡檢查時，自動標記息肉所在位置，並將偵測框內的影像轉換成紋路強化過後的影像輔助醫生在不進行 NBI 光源切換的情況下更好的進行診斷，同時自動預測該息肉的種類提供醫生做為參考，藉此減輕醫生的工作量。



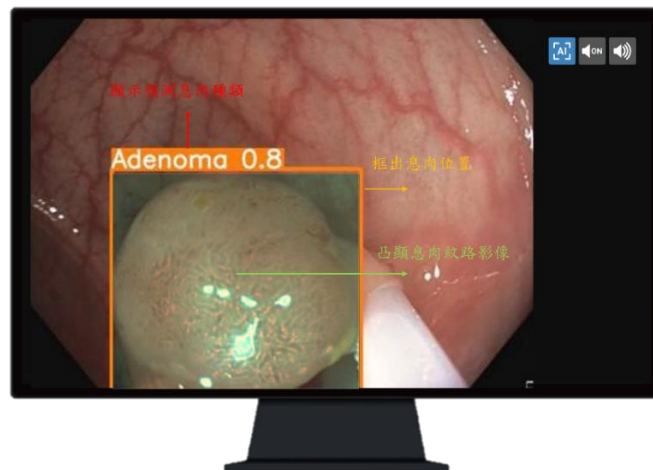
圖二十一、大腸息肉偵測模組：標記出大腸息肉發生的位置。



圖二十二、大腸息肉紋路強化模組：方法一，利用影像強技術加強息肉紋路對比度。



圖二十三、大腸息肉紋路強化模組：方法二，利用機器學習尋找白光到 NBI 的轉換公式。



圖二十四、大腸鏡整合模組：在進行大腸鏡檢查時能夠即時偵測息肉所在位置，並將偵測框內的息肉影像進行紋路凸顯處理，同時顯示分類結果在偵測框的上方。

預計可能之困難與解決途徑：

困難一：大腸息肉偵測模組準確率不夠高？

解決途徑：(1) 考慮採用更有效率之 YOLO 版本來應用或 (2) 再增加層數，以提高階層式特徵的有效性，來提升多層自我組織映射圖之可解讀性之學習模型的準確性。

困難二：大腸息肉分類模組在面對未見過之息肉影像時準確率不夠高？

解決途徑：(1) 採用人工標註以及影像增強的方式增加訓練資料集的數量或 (2) 考慮採用更廣、更深的 CNN 模型或 (3) 再增加層數，以提高階層式特徵的有效性，來提升多層自我組織映射圖之可解讀性之學習模型的準確性。

困難三：大腸鏡整合模組是否能滿足醫生實際應用需求，以及時否能確實提升醫生的工作效率？

解決途徑：本計畫之內容確實與在醫院任職之經驗豐富的內視鏡醫生進行討論，在實作過程中也會持續邀請內視鏡醫生參與，對成果與成效進行即時反饋以利修正，確保本計畫之研究成果具有實際應用之價值。

參考文獻：

- [1] 衛生福利部國民健康署，108 年癌症登記報告。
- [2] Kudo, S. E., Tamura, S., Nakajima, T., Yamano, H. O., Kusaka, H., & Watanabe, H. (1996). Diagnosis of colorectal tumorous lesions by magnifying endoscopy. *Gastrointestinal endoscopy*, 44(1), 8-14.
- [3] Gono, K., Obi, T., Yamaguchi, M., Oyama, N., Machida, H., Sano, Y., ... & Endo, T. (2004). Appearance of enhanced tissue features in narrow-band endoscopic imaging. *Journal of biomedical optics*, 9(3), 568-577.

- [4] Iwatate, M., Ikumoto, T., Hattori, S., Sano, W., Sano, Y., & Fujimori, T. (2012). NBI and NBI combined with magnifying colonoscopy. Diagnostic and therapeutic endoscopy, 2012.
- [5] Muto, T., Bussey, H. J. R., & Morson, B. C. (1975). The evolution of cancer of the colon and rectum. Cancer, 36(6), 2251-2270.
- [6] Winawer, S. J., Zauber, A. G., Ho, M. N., O'Brien, M. J., Gottlieb, L. S., Sternberg, S. S., ... & National Polyp Study Workgroup. (1993). Prevention of colorectal cancer by colonoscopic polypectomy. New England Journal of Medicine, 329(27), 1977-1981.
- [7] Kim, N. H., Jung, Y. S., Jeong, W. S., Yang, H. J., Park, S. K., Choi, K., & Park, D. I. (2017). Miss rate of colorectal neoplastic polyps and risk factors for missed polyps in consecutive colonoscopies. Intestinal research, 15(3), 411.
- [8] Komeda, Y., Handa, H., Watanabe, T., Nomura, T., Kitahashi, M., Sakurai, T., ... & Kudo, M. (2017). Computer-aided diagnosis based on convolutional neural network system for colorectal polyp classification: preliminary experience. Oncology, 93(Suppl. 1), 30-34
- [9] Patel, K., Li, K., Tao, K., Wang, Q., Bansal, A., Rastogi, A., & Wang, G. (2020). A comparative study on polyp classification using convolutional neural networks. PloS one, 15(7), e0236452.
- [10] C. -Y. Wang, A. Bochkovskiy, H. -Y. M. Liao, "YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors," arXiv:2207.02696, 2022.
- [11] Piccolo datasets, <https://www.biobancovasco.org/en/Sample-and-data-e-catalog/Databases/PD178-PICCOLO-EN1.html>.

(三) 預期完成之工作項目及成果。

第一年：

預期完成之工作項目：

- (1) 開發多層自我組織映射圖之可解讀性之深度學習模型。
- (2) 採用多層自我組織映射圖之可解讀性之深度學習模型於物件辨識之應用。
- (3) 採用多層自我組織映射圖之可解讀性之深度學習模型於音訊辨識之應用。
- (4) 論文撰寫。

參與之工作人員，預期可獲之訓練：

- (1) 了解自我組織映射圖原理。
- (2) 可解可解讀性之人工智慧模型。
- (3) 學會物件辨識和音訊辨識技術。
- (4) 論文撰寫能力；
- (5) 可申請專利。

第二年：

預期完成之工作項目：

- (1) 持續深化多層自我組織映射圖之可解讀性之深度學習模型的架構和功能。
- (2) 完成「心臟血管擷取模組」。
- (3) 完成「鈣化斑塊偵測模組」。
- (4) 完成「鈣化斑塊血管分段定位模組」。
- (5) 完成「編輯工具模組」。
- (6) 完成「心臟血管鈣化偵測系統」。
- (7) 論文撰寫。

參與之工作人員，預期可獲之訓練：

- (1) 學會影像處理技術。
- (2) 學會心臟血管的 CT 醫學影像處理技術。
- (3) 學會 YOLO 模型。
- (4) 學會 CNN 模型。
- (5) 可提高計劃參加者之程式語言撰寫能力。
- (6) 培養跨領域之整合能力。
- (7) 論文撰寫能力。
- (8) 可申請專利。

第三年：

預期完成之工作項目：

- (1) 持續深化多層自我組織映射圖之可解讀性之深度學習模型的架構和功能。
- (2) 完成「大腸息肉偵測模組」。
- (3) 完成「大腸息肉紋路強化模組」。
- (4) 完成「白光與 NBI 影像分類模組」。
- (5) 完成「大腸息肉分類模組」。
- (6) 完成「大腸鏡整合模組」。
- (7) 完成「大腸息肉位置偵及分類測系統」。
- (8) 論文撰寫。

參與之工作人員，預期可獲之訓練：

- (1) 學會影像處理技術。
- (2) 學會大腸息肉影像處理技術。
- (3) 學會 YOLO 模型。
- (4) 學會 CNN 模型。
- (5) 可提高計劃參加者之程式語言撰寫能力。
- (6) 培養跨領域之整合能力。
- (7) 論文撰寫能力。
- (8) 可申請專利。